Intrinsic "AI for Industry Challenge" Kapsamında Deforme Olabilen Nesneler ve Kablo Montajı İçin İleri Düzey Robotik Manipülasyon Stratejileri

Yarışmanın Endüstriyel Bağlamı ve Deforme Olabilen Nesnelerin Manipülasyonu

Robotik ve yapay zeka kesişiminde fiziksel dünyanın otomasyonu, geleneksel olarak katı nesnelerin deterministik yörüngelerde manipülasyonuna dayanmaktadır. Ancak endüstriyel elektronik üretiminde, özellikle sunucu tepsilerinin (server trays) montajı ve kablo yönlendirmesi (cable routing) gibi işlemler, otomasyonun önündeki en büyük darboğazlardan birini oluşturmaktadır.[1] Deforme olabilen lineer nesnelerin (Deformable Linear Objects - DLO) sahip olduğu yüksek esneklik, sonsuz serbestlik derecesi ve öngörülemeyen dinamik davranışlar, klasik kontrol teorilerini ve önceden programlanmış deterministik sistemleri işlevsiz kılmaktadır.[3] Intrinsic ve Open Robotics tarafından organize edilen "AI for Industry Challenge", tam olarak bu endüstriyel problemi çözmeyi hedefleyen, $180,000 ödül havuzuna sahip ve otomasyon algoritmalarının sınırlarını zorlayan küresel bir yarışmadır.[1]

Mart 2026 ile Eylül 2026 tarihleri arasında sürecek olan bu rekabetçi süreç, donanım bağımsız algoritmaların simülasyondan gerçek dünyaya (sim-to-real) sorunsuz bir şekilde aktarılabilmesini merkeze almaktadır.[1] Yarışma mimarisi üç ana faza ayrılmıştır. Yeterlilik aşaması olan "Qualification" periyodu, katılımcıların yaklaşık iki buçuk ay boyunca açık kaynaklı simülatörler (Gazebo, MuJoCo, Isaac Sim) üzerinden modellerini eğitmesini ve kablo montajı görevini sanal ortamda çözmesini gerektirmektedir.[6] İkinci aşama olan "Phase #1", eleme sonucunda seçilen 30 yetkin takımın Intrinsic'in özel geliştirme ortamı Flowstate'e ve endüstri standartlarını belirleyen Intrinsic Vision Model (IVM) altyapısına erişimini sağlayarak karmaşık kablo işleme çözümlerinin geliştirilmesine olanak tanır.[5] Nihai aşama olan "Phase #2" ise, en başarılı takımların algoritmalarının Intrinsic genel merkezinde bulunan gerçek bir fiziksel robotik hücrede (workcell) test edilmesini ve değerlendirilmesini içermektedir.[1]

Bu aşamalı yapı, geliştirilecek politikanın (policy) yalnızca simülasyon dinamiklerine aşırı uyum (overfitting) sağlamasını engellemekle kalmayıp, fiziksel dünyanın gürültülü ve belirsiz yapısına karşı dirençli (robust) olmasını zorunlu kılmaktadır. Deforme olabilen nesnelerin manipülasyonu literatürü, bu tür temas zengini (contact-rich) görevlerin sadece bir yörünge optimizasyonu problemi olmadığını, aksine eşzamanlı bir kısıtlı optimizasyon (constrained optimization) ve gerçek zamanlı adaptif kontrol problemi olduğunu vurgulamaktadır.[7] Bu nedenle, tasarlanacak makine öğrenmesi kurgusunun, yarışmanın sağladığı donanım arayüzleri, sensör geri bildirim

mekanizmaları ve kontrolcü dinamikleri ile kusursuz bir uyum içinde çalışması gerekmektedir.

Fiziksel Çevre, Donanım Spesifikasyonları ve Algısal Gözlem Uzayı

Geliştirilecek yapay zeka politikasının dış dünyayı algılama ve anlama kapasitesi, yarışma komitesi tarafından sağlanan araç setindeki (toolkit) sensör donanımlarıyla doğrudan sınırlıdır. Bu donanım konfigürasyonunun analizi, durum uzayının (state space) nasıl formüle edileceğini belirleyen en kritik adımdır. Yarışma kapsamında sunulan fiziksel robotik hücre, Universal Robots tarafından üretilen UR5e manipülatörünü temel almaktadır.[6] Uç işlevci (end-effector) olarak, endüstriyel standartlarda hassas kavrama yeteneğine sahip Robotiq Hand-E tutucu (gripper) sisteme entegre edilmiştir.[6]

Robotun çevresiyle olan fiziksel etkileşimini ölçmek için ATI Industrial Automation tarafından üretilen Axia80 Kuvvet-Tork (Force-Torque) sensörü kullanılmaktadır.[6] Görsel algı (perception) sistemi ise, robotun bileğine monte edilmiş üç adet Basler AG kameradan oluşmaktadır.[6] Bu kameralar, saniyede 20 kare (20 fps) hızında sıkıştırılmamış (uncompressed) RGB görüntü akışı sağlayarak politikanın görsel girdisini oluşturur.[1] Hedef montaj panosunda (task board) ise yüksek sadakatli ağ kartları (network cards) ve esnek kablo modelleri yer almaktadır.[8]

Bu donanım mimarisi incelendiğinde, sistemin çok modlu (multimodal) ve yüksek boyutlu bir gözlem uzayına sahip olduğu açıkça görülmektedir. Çözüm kurgusunun veri işleme kapasitesi, aşağıdaki sensör modalitelerini eşzamanlı olarak işleyebilmelidir.

Sensör / Veri Kaynağı	**Veri Formatı ve Çözünürlüğü**	**Stratejik İşlevi ve Operasyonel Rolü**
Bilek Kameraları (3 Adet)	Sıkıştırılmamış RGB, 20 Hz	Kablonun anlık şekil deformasyonunun tahmini, soketlerin 6D uzamsal poz tahmini ve oklüzyon (kapanma) etkilerinin çoklu açıyla telafi edilmesi.[1]
Axia80 F/T Sensörü	6 Eksenli Kuvvet/Tork Vektörü	Temas zengini montaj sırasında hedefe uygulanan kuvvetin ölçülmesi, aşırı yüklenmelerin engellenmesi ve güvenlik kısıtlarının korunması.[6]

UR5e Propriyosepsiyon	Eklem Açıları, Hızlar ve Uç İşlevci Pozu	Robotun kendi kinematik durumunu takip etmesi, çarpışma algılaması ve üretken modeller için durum koşullandırmasının (state conditioning) sağlanması.[1]
Robotiq Hand-E	Tutucu Açıklığı ve Durumu	Esnek kablonun ne kadar sıkı tutulduğunun kontrolü ve kayma (slippage) dinamiklerinin yönetilmesi.[6]

Gözlem uzayının sadece RGB görüntülerden oluşmaması, kuvvet ve propriyoseptif verilerin sisteme dahil edilmesi, geliştirilecek politikanın kör (blind) yörünge takibi yapmak yerine dokunsal farkındalığa (tactile awareness) sahip olmasını gerektirir. Kablonun sokete yerleştirilmesi sırasında milimetrik bir hata, vizyon sistemleri tarafından algılanamayacak kadar küçük olsa bile, kuvvet sensörü anında bir direnç dalgalanması tespit edecektir. Bu nedenle kurgunun temel taşı, bu çoklu sensör akışlarını gerçek zamanlı olarak birleştiren (sensor fusion) bir mimari olmalıdır.

Yazılım Altyapısı: ROS 2 Yaşam Döngüsü, Middleware ve Kontrolcü Dinamikleri

Donanım spesifikasyonlarının ötesinde, modelin simülasyon ve gerçek dünya ile nasıl haberleşeceği yarışmanın belirlediği yazılım kurallarına tabidir. Intrinsic, veri akışının kesintisiz ve standartlara uygun olması için "aic_model" adında hazır bir ROS 2 Yaşam Döngüsü (Lifecycle) düğümü (node) sunmaktadır.[9] Katılımcıların, derin öğrenme veya pekiştirmeli öğrenme tabanlı politikalarını saf Python sınıfı (class) olarak yazmaları ve bu düğüm içerisine dinamik olarak yüklemeleri beklenmektedir.[9] Bu yaklaşım, geliştiricileri ROS 2'nin karmaşık abone/yayıncı (subscriber/publisher) kod bloklarını (boilerplate) yazmaktan kurtararak doğrudan politika mantığına odaklanmalarını sağlar.[9]

Sistemin veri taşıma omurgası (backbone), yüksek performanslı RMZ (rmw_zenoh) middleware üzerine inşa edilmiştir.[8] Zenoh kullanımı, özellikle 3 adet sıkıştırılmamış RGB kamera akışının [1] ve yüksek frekanslı kuvvet verisinin ağ üzerinde darboğaz (bottleneck) yaratmadan taşınması için kritik bir mühendislik kararıdır. Geliştirilecek yapay zeka modelinin bu altyapıya entegrasyonunda, /insert_cable eylemi tetiklendiğinde harekete geçen ve /joint_states, /tcp_force_torque ile kamera başlıklarından (topics) gelen verileri senkronize bir şekilde alıp işleyen bir yapı kurulmalıdır.[1]

Yazılım mimarisindeki en belirleyici kısıt, frekans asimetrisidir. Intrinsic tarafından geliştirilen ve hem simülasyonda hem de gerçek robotta çalışan özel Empedans Kontrolcüsü (Impedance

Controller), son derece pürüzsüz ve kararlı hareketler üretebilmek için saniyede 500 Hz gibi çok yüksek bir frekansta çalışmaktadır.[8] Ancak, yapay zeka politikalarının (özellikle devasa parametreli VLA veya Difüzyon modellerinin) bu hızda çıkarım (inference) yapması mevcut donanımlarla (RTX 4090 veya A100 GPU'lar) mümkün değildir.[10] Bu nedenle kontrolcü, yapay zeka politikasından gelen hedef komutlarını (setpoints) 10 ila 30 Hz frekans aralığında kabul edecek ve aradaki boşlukları kendi iç dinamikleriyle dolduracak şekilde tasarlanmıştır.[8]

Bu asimetrik frekans yapısı (Politika Çıkarım Hızı: ~20 Hz, Kontrolcü Hızı: 500 Hz), tasarlanacak modelin "Aksiyon Gruplama" (Action Chunking) yeteneğine sahip olmasını zorunlu kılar. Politika, her 50 milisaniyede bir anlık eylem (single action) üretmek yerine, gelecekteki N adımlık bir yörünge dizisini paket halinde üretmeli ve kontrolcüye iletmelidir. Bu yöntem, model-predictive control (MPC) mantığına benzer bir işleyiş sunarak haberleşme gecikmelerinin ve çıkarım sürelerinin robotun hareketini kesintiye uğratmasını engeller.[11]

Değerlendirme Metriklerinin Sistematik Analizi ve Optimizasyon Kriterleri

Algoritmik kurgunun hangi hedef fonksiyonuna göre optimize edileceğini belirlemek için yarışmanın puanlama ve değerlendirme metrikleri derinlemesine incelenmelidir. Otonom bir sistemin başarılı sayılması için sadece kabloyu sokete takması yeterli değildir; bu işlemin nasıl yapıldığı da büyük önem taşır. Değerlendirme komitesi, modellerin geçerliliğini (model validity) onayladıktan sonra şu dört temel metriği uygulayacaktır [1]:

1. **Görev Başarısı (Task Success):** Başarıyla takılan her kablo konnektörü için atanan ikili (binary) temel başarı ölçütüdür. Sistemin deterministik olmayan çevrelerde, örneğin kablonun bükülme noktasının değiştiği durumlarda bile hedef noktayı bulabilme kapasitesini test eder.
2. **Hassasiyet (Precision):** Kablo konnektörlerinin hedef soketlere ne kadar yakın ve hizalı yerleştirildiğini ölçen sürekli (continuous) bir skaler değerdir. Bu metrik, görsel algılama ağının 6D poz tahmini başarımını ve robotik manipülatörün kinematik ters çözüm doğruluk oranını doğrudan değerlendirir.
3. **Güvenlik (Safety):** Modelin çevresiyle olan fiziksel etkileşiminin şiddetini kontrol eder. Robotun çevreye çarpması veya montaj sırasında konnektörlere/kablolara aşırı kuvvet uygulaması durumunda çok ağır ceza puanları (penalties) kesilir. Literatürde, deforme olabilen elektronik bileşenlerin montajında tespit edilen 30 Newton ve üzeri çarpışma kuvvetleri, güvenlik ihlali ve donanım hasarı olarak sınıflandırılmaktadır.[12]
4. **Verimlilik (Efficiency):** Tüm montaj görevlerinin baştan sona tamamlanması için geçen toplam döngü süresini (cycle time) ölçer. Daha kısa sürede başarıya ulaşan modeller ödüllendirilir. Bu durum, modelin serbest uzayda (free-space) hızlı, dar alanlarda (contact-space) ise yavaş ve temkinli hareket etmesini gerektiren adaptif bir hız politikası gütmesini zorunlu kılar.

Bu dört kısıt bir araya getirildiğinde, ortaya çıkan ideal model profili şudur: Hedef noktaya optik akış veya uzamsal hizalama ile hızla giden, ancak sokete yaklaştığında kuvvet sensöründen gelen geri bildirime dayanarak hızını düşüren, esnekleşen ve hata durumunda yörüngesini kırılmadan düzeltebilen bir mimari. Değerlendirme sisteminin ROS 2 telemetrisi, Nav2 yığını metrikleri ve yüksek kardinaliteli zaman serisi depolama (high-cardinality time series storage) kullanan özel bir korelasyon motoru ile destekleneceği bildirilmiştir.[13] Bu nedenle, politikanın ürettiği komutların sinyal gürültü oranının düşük olması hayati önem taşır.

Karar Verme Paradigması: Çevrimiçi Pekiştirmeli Öğrenmenin (Online RL) Yetersizlikleri

Bu denli karmaşık, yüksek boyutlu gözlemlere ve sıkı güvenlik metriklerine sahip bir problemin çözümünde ilk akla gelen yöntem, ajanın çevreyle doğrudan etkileşime girerek deneme-yanılma yoluyla stratejiler geliştirdiği Çevrimiçi Pekiştirmeli Öğrenmedir (Online Reinforcement Learning). Proksimal Politika Optimizasyonu (PPO) veya Yumuşak Aktör-Eleştirmen (SAC) gibi geleneksel algoritmalar ile SimbaV2, BRO veya FastSAC gibi SOTA varyantları literatürde sürekli kontrol problemleri için sıklıkla kullanılmaktadır.[14] Ancak "AI for Industry Challenge" bağlamında Çevrimiçi RL yaklaşımının kurgulanması üç temel nedenden ötürü stratejik bir hatadır.

İlk olarak, örneklem verimsizliği (sample inefficiency) büyük bir sorundur. RGB kameralardan gelen piksel verileri üzerinden sıfırdan bir kontrol politikası öğrenmek, milyonlarca simülasyon adımı gerektirir. Kabloların deforme olabilir yapısının yarattığı rastlantısallık (nondeterminism) ve yüksek varyans, durum uzayının keşfedilmesini geometrik olarak zorlaştırarak eğitim sürelerini pratik olmayan seviyelere çıkarır.[15] Amazon FAR projesindeki gibi insanımsı robotların 15 dakikada simülasyondan gerçeğe öğrenmesi gibi ekstrem örnekler bulunsa da [14], bunlar genellikle eklem kinematiğine dayalı yürüyüş görevleridir; kablo montajı gibi görsel-dokunsal füzyon gerektiren ince motor (dexterous manipulation) görevleri değildir.

İkinci ve en kritik sorun, Güvenlik kısıtları ve Simülasyondan Gerçeğe (Sim-to-Real) aktarım uçurumudur. Çevrimiçi RL algoritmaları doğaları gereği rastgele keşif (random exploration) yaparlar. Simülasyon ortamında herhangi bir risk teşkil etmeyen bu keşif adımları, Faz 2'deki fiziksel UR5e robotuna yüklendiğinde felakete yol açabilir. Çevrimiçi RL'nin dağılım dışı (out-of-distribution) bir durumla karşılaştığında üreteceği ani ve şiddetli hareketler, doğrudan "Güvenlik" ceza puanlarına ve potansiyel robot veya görev panosu hasarına neden olacaktır.[15] Model serbest (model-free) çevrimiçi RL'nin güvenlik garantileri sağlamaması, fiziksel temas barındıran endüstriyel ortamlarda uygulanabilirliğini sıfıra indirir.[16]

Üçüncü sorun ise seyrek ödül (sparse reward) mimarisidir. Kablonun hedefe milimetrik bir şekilde yerleştirilmesi işlemi, sürecin büyük bir bölümünde ajana hiçbir ödül sinyali döndürmeyen, sadece başarı veya başarısızlık durumunda ikili bir sinyal üreten bir yapıdır. Ödül şekillendirme (reward shaping) teknikleri ile bu durum hafifletilmeye çalışılsa da, deforme olabilen nesnelerde geçici durumlara (ara şekillere) ödül atamak insan mühendisliği açısından son derece zahmetlidir ve ajanın istenmeyen yan davranışlar (reward hacking) geliştirmesine yol

açar.[15]

Çevrimdışı Pekiştirmeli Öğrenme (Offline RL): Teorik Sınırlar ve Olasılık Dağılımları

Çevrimiçi RL'nin risklerini bertaraf etmek amacıyla, doğrudan uzman gösterimlerinden veya önceden toplanmış devasa durum-eylem-ödül (state-action-reward) geçiş veri setlerinden öğrenmeyi hedefleyen Çevrimdışı Pekiştirmeli Öğrenme (Offline RL) mimarileri kurgu adayı olarak incelenmelidir. Offline RL, çevresel etkileşime ihtiyaç duymadan, hesaplama maliyetlerini düşürerek ve eğitim kararlılığını artırarak yüksek veri verimliliği sağlar.[18]

Bu alandaki temel algoritmalar, dağılım dışı eylemlerin değerlerini kötümser (pessimistic) bir şekilde tahmin ederek aşırı değerlemeyi (overestimation) önleyen Muhafazakar Q-Öğrenme (Conservative Q-Learning - CQL), Davranış Klonlama ile düzenlenmiş Çift Gecikmeli Derin Belirleyici Politika Gradyanı (TD3+BC) ve Örtük Q-Öğrenme (Implicit Q-Learning - IQL) olarak sıralanabilir.[17] Çevrimdışı ortamda, IQL ve CQL gibi modellerin özellikle robotik montaj ve deforme olabilen nesnelerde başarılı sonuçlar verdiği, görsel gözlemlerle sıfırdan eğitildiklerinde yüksek kazanımlar sağladığı literatürde mevcuttur.[19]

Ancak, Offline RL yaklaşımları bu yarışmanın spesifik kısıtlarına tam olarak cevap veremez. Kablo montajında, belirli bir sonuca ulaşmak için çok sayıda farklı ancak eşit derecede geçerli yörünge bulunabilir. Örneğin, bir kabloyu kavramak için sol taraftan 30 derece açıyla yaklaşmak veya sağ taraftan 45 derece açıyla yaklaşmak geçerli hareketlerdir. Offline RL mimarilerinde sıklıkla kullanılan tek modlu (unimodal) Gauss aktör ağları (actor networks), veri setindeki bu farklı modları gördüğünde, iki geçerli hareketin ortalamasını (mean) almaya çalışır. Sağ ve sol yaklaşımın ortalamasını almak, robotun doğrudan hedefe cepheden çarpmasına ve "Güvenlik" metriklerinin ihlal edilmesine yol açan yıkıcı bir eylem üretir.[21] Karışım Yoğunluk Modelleri (Mixture Density Models - MDM) bu sorunu çözmek için kullanılsa da, yüksek boyutlu eylem uzaylarında (6D poz + gripper + empedans) istikrarsızlık gösterirler.[22] Ayrıca, veri dağılımında yaşanacak ufak bir sapmada (distribution shift), Offline RL politikalarının aşırı uyum (overfitting) gösterme riski oldukça yüksektir.[18]

Üretken Yapay Zeka ve Taklitçi Öğrenme: "Action Chunking" ve Difüzyon Politikaları

Çevrimiçi ve çevrimdışı pekiştirmeli öğrenmenin sınırları, endüstriyel robotikteki güncel paradigma değişimini Taklitçi Öğrenme (Imitation Learning - IL) ve Üretken Politikalar (Generative Policies) yönüne kaydırmıştır. Intrinsic yarışmasının gereksinimleri, LeRobot entegrasyonu ve literatürdeki SOTA uygulamaları göz önüne alındığında, kurgulanması gereken mimariler Transformer Destekli Aksiyon Gruplama (Action Chunking with Transformers - ACT) ve Difüzyon Politikaları (Diffusion Policy) etrafında şekillenmelidir.[22]

Algoritma / Yaklaşım	Temel Mekanizma	Avantajlar	Yarışma Bağlamındaki Rolü
ACT (Action Chunking with Transformers)	Eylemleri tekil olarak değil, zamansal bloklar (chunk) halinde tahmin eden Transformer mimarisi.	Zamansal tutarlılık sağlar, hata birikimini (compounding error) minimize eder. Pürüzsüz görev icrası sunar.[22]	Kontrolcü ile 10-30Hz frekans kısıtını aşmak ve düzgün (smooth) yörüngeler üretmek için temel mimari blok.[23]
Diffusion Policy (Difüzyon Politikası)	Saf gürültüden (noise) başlayarak, durumu koşul (condition) alıp eylemi iteratif olarak temizleme süreci.[21]	İfade gücü en yüksek modeldir. Sonsuz sayıda çok modlu eylem dağılımını (multimodal action distributions) temsil edebilir.[21]	İnsan gösterimlerindeki tüm karmaşık kablo yakalama stratejilerini kayıpsız olarak klonlar ve uygular.
VLA (Vision-Language-Action) Modelleri	Pi0, SmolVLA gibi görsel ve dil verilerini robot eylemlerine çeviren büyük modeller.[10]	Sıfır atış (zero-shot) yetenekleri yüksektir, çoklu görev (multi-task) esnekliği sağlar.	Yarışma tek bir spesifik göreve odaklandığı için, 3.5 Milyar parametreli Pi0 yerine [10], daha spesifik eğitilmiş ACT veya Difüzyon tercih edilmelidir.

Difüzyon Politikaları, robot eylem uzayında koşullu gürültü giderme (conditional denoising diffusion process) prensibiyle çalışır.[21] Doğrudan tek bir eylem tahmini yapmak yerine, politika görsel ve dokunsal gözlemlere bağlı olarak (conditioned on observations), K adımda gürültü giderme yinelemesi gerçekleştirir.[21] Öğrenilen skor fonksiyonunun (score function) gradyanı üzerinde Stokastik Langevin Dinamikleri kullanılarak örnekleme (sampling) yapılır. Bu yapı, difüzyon modellerinin görüntü üretiminde ulaştığı üstün çok modlu ifade yeteneğini doğrudan fiziksel manipülasyon uzayına taşır.[21]

Ayrıca, ACT modelinin temelini oluşturan zamansal topluluk (temporal ensembling) yöntemi, dağılım dışı eylemlerin etkisini sınırlar.[23] Her bir zaman adımında politika birden fazla örtüşen eylem dizisi (chunk) tahmin eder ve bu tahminlerin ağırlıklı ortalaması (veya seçimi) robot komutu olarak iletilir. Difüzyon politikaları, bu *Action Chunking* konseptiyle birleştirilerek,

yarışmanın 500 Hz'lik Empedans Kontrolcüsüne 10-30 Hz aralığında kararlı ve titremesiz yörüngeler sağlayabilecek yegane SOTA yaklaşımdır.

Çoklu Görüş ve Kuvvet Farkındalıklı Difüzyon Politikası (Multi-View Force-Aware Diffusion)

Yarışma kurgusunun merkezinde, salt görselliğe dayalı politikaların zayıflıklarını gidermek amacıyla Çoklu Görüş ve Kuvvet Farkındalıklı Difüzyon Politikası (Multi-View Force-Aware Diffusion Policy) yer almalıdır. Üç adet 20fps RGB kameradan gelen veriler, tek bir 2D görüntü olarak yığılmak (stacking) yerine, hiyerarşik veya 3D izdüşümlü (lifting) özellik çıkarımı süreçlerinden geçirilmelidir.

Görsel algıdaki oklüzyonları gidermek için çoklu görüş (multi-view) stratejileri zorunludur. Örneğin, M4Diffuser veya 3D Diffuser Actor gibi yaklaşımlar, farklı kamera açılarından gelen 2D özellikleri (ResNet veya ViT tabanlı kodlayıcılardan geçen) ortak bir 3D koordinat çerçevesine aktararak sahne yerleşiminin küresel bağlamını (global scene context) yakalar.[25] M4Diffuser'ın gösterdiği gibi, çoklu kamera füzyonu geleneksel planlama yöntemlerine kıyasla başarı oranını %28.4 artırırken, çarpışmaları %69 oranında azaltmaktadır.[26] Bu sonuçlar, yarışmadaki "Hassasiyet" ve "Güvenlik" metriklerinde doğrudan zirveye oynamayı sağlar.

Bununla birlikte, yalnızca çoklu görüş yeterli değildir. Temas zengini (contact-rich) endüstriyel kablo montajı, oklüzyonun kaçınılmaz olduğu ve vizyonun yetersiz kaldığı mikrometrik toleranslara sahiptir. Burada Axia80 kuvvet-tork sensörü devreye girer. FARM (Force-Aware Robotic Manipulation) difüzyon politikası gibi literatürdeki en güncel (SOTA) yaklaşımlar, kuvvet bilgisini hem gözlem uzayına hem de eylem uzayına entegre etmektedir.[27] Kuvvet verisi, zaman içindeki değişimi yakalamak için bir zamansal pencere (temporal window) ile MLP veya 1D Evrişimli Sinir Ağlarından (1D CNN) geçirilerek yüksek boyutlu bir özellik vektörüne dönüştürülür. Daha sonra bu vektör, kamera özellikleri ile bir Çapraz Dikkat (Cross-Attention) mekanizması vasıtasıyla birleştirilir.[28] Batarya sökme/takma gibi karmaşık temas zengini görevlerde, kuvvet entegrasyonlu difüzyon politikalarının, sadece vizyon kullanan modellere kıyasla %57'lik bir iyileşme ile başarı oranını %96'ya çıkardığı kanıtlanmıştır.[28] Kuvvetin difüzyon koşullandırmasına (conditioning) eklenmesi, sistemin mod geçişlerinde (serbest uzaydan temas uzayına geçiş) inanılmaz bir dayanıklılık (robustness) sergilemesini sağlar.[28]

Değişken Empedans Kontrolü (Variable Impedance Control) ve Eylem Uzayının Genişletilmesi

Kuvvet farkındalığının yalnızca gözlem yapmakla sınırlı kalmaması, robotun çevreye uyguladığı kuvveti modüle etmesi için eylem uzayının (action space) genişletilmesi gereklidir. Geleneksel yaklaşımlar eylem uzayını sadece konum, oryantasyon ve tutucu durumu olarak tanımlar: $a = [x, y, z, \text{roll}, \text{pitch}, \text{yaw}, g]$. Ancak yarışmanın sağladığı 500 Hz Empedans Kontrolcüsü [8], eylem uzayına sertlik (stiffness) ve sönümleme (damping) parametrelerinin de

dahil edilmesine olanak tanır.

Robotun uç işlevcisi, bir kütle-yay-sönümleyici (mass-spring-damper) sistemi olarak modellendiğinde dinamik denklem şu şekildedir:

$$M\ddot{x} + B\dot{x} + K(x - x_{hedef}) = F_{ext}$$

Burada K, yayın sertliğini (stiffness), F_{ext} ise çevreye uygulanan etkileşim kuvvetini temsil eder.[29]

Yarışmadaki "Güvenlik" metriğinde ceza yememek ve konnektörü zorla kırmamak için, geliştirilecek Difüzyon Politikası, kartezyen pozlarla birlikte K_x, K_y, K_z (ve rotasyonel K_ψ) hedef empedans değerlerini de çıktı olarak vermelidir.[30] Eylem vektörü şu şekilde genişletilir:

$$a_t = [x_t, y_t, z_t, \text{roll}_t, \text{pitch}_t, \text{yaw}_t, g_t, K_{x,t}, K_{y,t}, K_{z,t}]$$

Bu "Değişken Empedans Kontrolü" (Variable Impedance Control - VIC) kurgusu, CompliantVLA veya IMP-HRL gibi mimarilerde kullanılmaktadır.[16] Sistemin davranışı şu şekilde optimize edilecektir:

1. **Serbest Uzay (Free Space):** Robot kabloyu ararken ve hedefe doğru yaklaşırken politika yüksek K (sertlik) değerleri üretir. Robot rijit bir şekilde ve yüksek hızda hareket ederek "Verimlilik" (Cycle Time) puanını maksimize eder.
2. **Temas Fazı (Contact Phase):** Konnektör deliğe girmeye başladığında, F/T sensöründen gelen direnç verisi difüzyon modeline ulaşır. Model anında K değerlerini düşürerek robotu "uyumlu" (compliant) hale getirir. Robot, deliğe girmek için aşırı kuvvet uygulamak yerine, yay gibi esneyerek yuvasını bulur. Güvenlik limiti olan >30N seviyesine asla ulaşılmaz.[12]

Bu yaklaşım, model-free pekiştirmeli öğrenme tabanlı güvenli keşif ve değişken empedans denetleyici birleşimi (SRL-VIC) mimarilerine paralel olarak, çarpışmaların önüne geçmekte ve en yapılandırılmamış (unstructured) ortamlarda bile donanım güvenliğini garanti altına almaktadır.[16]

Veri Toplama, LeRobot Entegrasyonu ve Simülasyondan Gerçeğe (Sim-to-Real) Geçiş

Difüzyon politikasının kalbi, eğitim verisinin kalitesidir. Intrinsic'in yarışma paketine Hugging Face'in "LeRobot" çerçevesini entegre etmiş olması, devasa bir stratejik avantaj sunmaktadır.[8] LeRobot, uçtan uca robot öğrenimi için tasarlanmış, ACT, Difüzyon ve VLA gibi modelleri PyTorch üzerinde destekleyen, donanım ve simülasyon arası veri akışını standartlaştıran SOTA bir kütüphanedir.[10]

Eğitim setinin oluşturulması için, 3D fareler (SpaceMouse) veya sanal gerçeklik (VR) kumandaları gibi teleoperasyon cihazları kullanılarak uzman gösterim (expert demonstration) verisi toplanacaktır.[34] Bu veriler, Hugging Face Hub üzerinde LeRobotDataset formatında saklanır. Bu format, kameralardan gelen yüksek bant genişlikli veriyi senkronize MP4 videoları olarak, durum/eylem/kuvvet verilerini ise yapılandırılmış Parquet dosyaları olarak tutar.[36] Veri parçalanması sorununu çözen bu yapı, eğitim aşamasında GPU I/O darboğazlarını engelleyerek RTX 4090 veya A100 sistemlerinde hızla sonuç alınmasını sağlar.[10] ACT modelinin sadece 52M, Difüzyon modelinin ise 263M parametreye sahip olması [10], modellerin standart bulut sunucularında kolayca eğitilebileceğini ve Faz-2'de yarışma bilgisayarlarında çıkarım hızlarına rahatça ulaşabileceğini gösterir.

Simülasyondan gerçeğe geçiş (Sim-to-Real gap), fiziksel dünyada kabloların esnekliğinin simülatörlerde (Gazebo, MuJoCo) mükemmel kurgulanamamasından kaynaklanan kayıpları içerir.[37] NVIDIA Omniverse üzerine kurulu Isaac Sim (veya Isaac Lab) kullanılarak paralel çevrelerde "Alan Rastgeleştirme" (Domain Randomization) uygulanmalıdır.[5] Kabloların kütlesi, bükülme rijitliği, kamera sensörlerinin aydınlatma koşulları ve arka plan tekstürleri rastgele değiştirilerek, difüzyon politikası görsel gürültüye karşı bağışık (immune) hale getirilir. Böylelikle, Gazebo'da (yarışmanın resmi simülasyon motoru) çalıştırıldığında veya fiziksel UR5e kolunda test edildiğinde model çökmesi yaşanmaz.[6]

Intrinsic Flowstate ve Intrinsic Vision Model (IVM) İle Faz-1 / Faz-2 Entegrasyonu

Modelin Yeterlilik aşamasında başarılı olması durumunda Faz 1'e geçilecek ve Intrinsic Flowstate ile Intrinsic Vision Model (IVM) ekosistemine erişim sağlanacaktır.[5] Bu durum önceden öngörülmeli ve kurgulanan mimari bu araçlarla modüler olarak birleşecek yapıda olmalıdır.

Intrinsic Vision Model (IVM), endüstriyel algı sistemlerinde devrim niteliğinde bir foundation modeldir. Yakın zamanda düzenlenen ICCV 2025 BOP (Benchmark for 6D Object Pose Estimation) yarışmasında on bir kıyaslama kategorisinin yedisinde birinci olarak SOTA olduğunu kanıtlamıştır.[5] IVM'in en vurucu özelliği "CAD-native" olması ve standart RGB kameralarla (derinlik veya LiDAR sensörü kullanmadan) milimetre altı hassasiyet (sub-millimeter accuracy) sağlamasıdır.[39] Bu, derinlik sensörlerinin şeffaf veya yansıtıcı yüzeylerde yaşadığı sorunları ortadan kaldırır.[40]

Geliştirdiğimiz Çoklu Görüşlü Difüzyon Politikasının görsel kodlayıcı (visual encoder) katmanı, Faz 1'e geçildiğinde IVM vektör alanıyla hizalanacak şekilde tasarlanmalıdır. IVM'in ürettiği yüksek

hassasiyetli 6D poz özellikleri, doğrudan difüzyon ağının koşullandırma (conditioning) girdisine beslenerek, "Hassasiyet" (Precision) metriğinde alınacak puan maksimize edilir. Ayrıca Intrinsic Flowstate platformunun davranış ağaçları (behavior trees) ve düğüm tabanlı görsel programlama altyapısı sayesinde [41], difüzyon politikasının hata yönetimi (error recovery) süreçleri endüstriyel standartlarda kodlanabilecektir. Foxconn ile yapılan ortak girişim (Joint Venture) de dikkate alındığında [38], Flowstate ekosistemiyle uyumlu bir yapay zeka modelinin sadece yarışmada değil, genel elektronik üretim süreçlerinde de doğrudan ticarileşme potansiyeli yüksektir.

Nihai Sistem Mimarisi ve Uygulama Stratejisi

Tüm analizler ve yarışma gereksinimleri doğrultusunda, Intrinsic "AI for Industry Challenge" için tasarlanan nihai kurgunun mimari bileşenleri ve veri akışı şu şekilde yapılandırılmalıdır:

1. **Sensör Veri Senkronizasyonu:** ROS 2 aic_model yaşam döngüsü düğümü içerisinde message_filters kütüphanesi ile Zaman Damgası Senkronizasyonu (ApproximateTimeSynchronizer) kurularak, üç bilek kamerası ve F/T sensörü verileri tam uyumlu olarak alınır.
2. **Özellik Çıkarımı (Feature Extraction):** RGB görüntüleri IVM uyumlu veya ResNet/ViT tabanlı kodlayıcılardan geçerek uzamsal özelliklere, F/T sensöründen gelen zaman serisi kuvvet verileri ise 1D-CNN üzerinden kuvvet özelliklerine dönüştürülür. Çapraz dikkat (Cross-Attention) ile birleştirilir.
3. **Difüzyon Çıkarım Motoru (Diffusion Inference Engine):** 10-30 Hz aralığında çalışan politika, koşullu gürültü giderme (conditional denoising) işlemi ile gelecekteki N adım için (Action Chunking) yörünge tahmini yapar.
4. **Eylem Kompozisyonu:** Çıktı, sadece (x, y, z) pozisyonunu değil, aynı zamanda güvenlik kısıtları için (K_x, K_y, K_z) değişken empedans sertlik değerlerini barındırır.
5. **Kontrolcü Entegrasyonu:** Üretilen paket yörünge ve empedans komutları, RMZ (Zenoh) middleware üzerinden 500 Hz'lik Empedans Kontrolcüsüne beslenerek pürüzsüz ve insan benzeri esnek manipülasyon sağlanır.

Bu bütüncül yapı, Çevrimiçi RL'nin keşif risklerini ve Çevrimdışı RL'nin tek modlu yetersizliklerini aşarak, deforme olabilen nesnelerin manipülasyonunda yarışmanın "Başarı, Hassasiyet, Güvenlik ve Verimlilik" metriklerinin tamamını optimize eden, literatürdeki en ileri düzey çözümü temsil etmektedir.

Alıntılanan çalışmalar

1. AI for Industry Challenge - Intrinsic, erişim tarihi Mart 29, 2026, https://www.intrinsic.ai/events/ai-for-industry-challenge
2. Conference Agenda for Automate Show, erişim tarihi Mart 29, 2026,

https://www.automateshow.com/agenda
3. Parametric modeling of deformable linear objects for robotic outfitting and maintenance of space systems - Frontiers, erişim tarihi Mart 29, 2026, https://www.frontiersin.org/journals/robotics-and-ai/articles/10.3389/frobt.2025.1565837/full
4. A Review of Robotic Manipulation Solutions for Deformable Linear Objects: The Case of Wire Harnesses (Co-)Assembly by Robots - ResearchGate, erişim tarihi Mart 29, 2026, https://www.researchgate.net/publication/400308082_A_Review_of_Robotic_Manipulation_Solutions_for_Deformable_Linear_Objects_The_Case_of_Wire_Harnesses_Co-Assembly_by_Robots
5. Enabling the next-generation developer ecosystem for intelligent robotics - Intrinsic, erişim tarihi Mart 29, 2026, https://www.intrinsic.ai/blog/posts/enabling-the-next-generation-developer-ecosystem-for-intelligent-robotics
6. AI for Industry Challenge | Challenge Details - Open Robotics Discourse, erişim tarihi Mart 29, 2026, https://discourse.openrobotics.org/t/ai-for-industry-challenge-challenge-details/52380
7. Deformable and Fragile Object Manipulation: A Review and Prospects - MDPI, erişim tarihi Mart 29, 2026, https://www.mdpi.com/1424-8220/25/17/5430
8. The AI for Industry Challenge Toolkit is LIVE! - Open Robotics Discourse, erişim tarihi Mart 29, 2026, https://discourse.openrobotics.org/t/the-ai-for-industry-challenge-toolkit-is-live/52861
9. intrinsic-dev/aic: Toolkit for the AI for Industry Challenge - GitHub, erişim tarihi Mart 29, 2026, https://github.com/intrinsic-dev/aic
10. LeRobot: An Open-Source Library for End-to-End Robot Learning - arXiv, erişim tarihi Mart 29, 2026, https://arxiv.org/html/2602.22818v1
11. Ch. 21 - Imitation Learning - Underactuated Robotics, erişim tarihi Mart 29, 2026, https://underactuated.mit.edu/imitation.html
12. Visuo-tactile feedback policies for terminal assembly facilitated by reinforcement learning, erişim tarihi Mart 29, 2026, https://www.frontiersin.org/journals/robotics-and-ai/articles/10.3389/frobt.2025.1660244/full
13. ROS2 correlation engine: kung paano namin ginawa ang awtomatikong pagbuo ng causal chain para sa production debugging : r/ROS - Reddit, erişim tarihi Mart 29, 2026, https://www.reddit.com/r/ROS/comments/1qnlls6/ros2_correlation_engine_how_we_built_automatic/?tl=fil
14. Current SOTA for continuous control? : r/reinforcementlearning - Reddit, erişim tarihi Mart 29, 2026, https://www.reddit.com/r/reinforcementlearning/comments/1pq7hee/current_sota_for_continuous_control/
15. Reinforcement Learning for Robotic Insertion of Flexible Cables in Industrial

Settings - arXiv, erişim tarihi Mart 29, 2026, https://arxiv.org/abs/2509.13731
16. SRL-VIC: A Variable Stiffness-Based Safe Reinforcement Learning for Contact-Rich Robotic Tasks - IEEE Xplore, erişim tarihi Mart 29, 2026, https://ieeexplore.ieee.org/iel7/7083369/10504377/10517611.pdf
17. Robot Learning for Deformable Object Manipulation Tasks - research.chalmers.se, erişim tarihi Mart 29, 2026, https://research.chalmers.se/publication/540359/file/540359_Fulltext.pdf
18. Diffusion models for robotic manipulation: a survey - PMC, erişim tarihi Mart 29, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12454101/
19. Bridging the Gap from Supervised Learning to Control - Computer Science, erişim tarihi Mart 29, 2026, https://cs.nyu.edu/media/publications/Brandfonbrener_Thesis.pdf
20. RL-100: Performant Robotic Manipulation with Real-World Reinforcement Learning - arXiv, erişim tarihi Mart 29, 2026, https://arxiv.org/html/2510.14830v3
21. Diffusion Policy: - Robotics, erişim tarihi Mart 29, 2026, https://www.roboticsproceedings.org/rss19/p026.pdf
22. Interactive imitation learning for dexterous robotic manipulation: challenges and perspectives—a survey - PMC, erişim tarihi Mart 29, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12757213/
23. Visuo-Tactile Pretraining for Cable Plugging - arXiv, erişim tarihi Mart 29, 2026, https://arxiv.org/html/2403.11898v1
24. End-to-End Learning for a Low-Cost Robotics Arm - Scholarship Repository @ Florida Tech, erişim tarihi Mart 29, 2026, https://repository.fit.edu/cgi/viewcontent.cgi?article=2546&context=etd
25. Multi-View Diffusion Policy - Emergent Mind, erişim tarihi Mart 29, 2026, https://www.emergentmind.com/topics/multi-view-diffusion-policy
26. 𝓜ulti-View Diffusion Policy with 𝓜anipulability-Aware Control for Robust 𝓜obile 𝓜anipulation - arXiv, erişim tarihi Mart 29, 2026, https://arxiv.org/html/2509.14980v1
27. Tactile-Conditioned Diffusion Policy for Force-Aware Robotic Manipulation - arXiv, erişim tarihi Mart 29, 2026, https://arxiv.org/html/2510.13324v1
28. Robotic Compliant Object Prying Using Diffusion Policy Guided by Vision and Force Observations - arXiv, erişim tarihi Mart 29, 2026, https://arxiv.org/html/2503.03998v1
29. Deep Reinforcement Learning of Variable Impedance Control for Object-Picking Tasks - Clemson OPEN, erişim tarihi Mart 29, 2026, https://open.clemson.edu/cgi/viewcontent.cgi?article=5282&context=all_theses
30. Impedance Primitive-augmented Hierarchical Reinforcement Learning for Sequential Tasks, erişim tarihi Mart 29, 2026, https://arxiv.org/html/2508.19607v1
31. CompliantVLA-adaptor: VLM-Guided Variable Impedance Action for Safe Contact-Rich Manipulation - arXiv, erişim tarihi Mart 29, 2026, https://arxiv.org/html/2601.15541v2
32. Compliant Force Control for Robots: A Survey - MDPI, erişim tarihi Mart 29, 2026, https://www.mdpi.com/2227-7390/13/13/2204
33. Training Robots with LeRobot: Teleoperation and AI for Pick-and-Place Tasks,

erişim tarihi Mart 29, 2026, https://techlabs-aachen.medium.com/training-robots-with-lerobot-teleoperation-and-ai-for-pick-and-place-tasks-d8a16a219af5
34. Learning Efficiently with Trajectory Data for Real World Robotics - UC Berkeley, erişim tarihi Mart 29, 2026, https://escholarship.org/content/qt6n68p115/qt6n68p115.pdf
35. Rearranging Deformable Linear Objects for Implicit Goals with Self-Supervised Planning and Control - ResearchGate, erişim tarihi Mart 29, 2026, https://www.researchgate.net/publication/385420072_Rearranging_Deformable_Linear_Objects_for_Implicit_Goals_with_Self-Supervised_Planning_and_Control
36. LeRobot: Making AI for Robotics more accessible with end-to-end learning - GitHub, erişim tarihi Mart 29, 2026, https://github.com/huggingface/lerobot
37. AI for Industry Challenge: Win $180,000 by Solving One of Manufacturing's Hardest Problems - Opportunities for Youth, erişim tarihi Mart 29, 2026, https://opportunitiesforyouth.org/2026/01/09/ai-for-industry/
38. Google Intrinsic AI Robotics Strategy Marks New Phase for Automation - The Tech Marketer, erişim tarihi Mart 29, 2026, https://thetechmarketer.com/google-intrinsic-ai-robotics-strategy-shift/
39. Intrinsic AI launches developer challenge and vision model as it seeks to energise intelligent-robotics ecosystem, erişim tarihi Mart 29, 2026, https://roboticsandautomationnews.com/2025/10/28/intrinsic-ai-launches-developer-challenge-and-vision-model-as-it-seeks-to-energise-intelligent-robotics-ecosystem/95984/
40. Intrinsic 3D vision system, erişim tarihi Mart 29, 2026, https://www.intrinsic.ai/research/intrinsic-3d-vision-system
41. Flowstate: Intrinsic's app to simplify the creation of robotics applications | The Construct, erişim tarihi Mart 29, 2026, https://www.theconstruct.ai/flowstate-intrinsics-app-to-simplify-the-creation-of-robotics-applications/
42. Alphabet's Robotics Software Platform Intrinsic Formally Integrates with Google - MLQ.ai, erişim tarihi Mart 29, 2026, https://mlq.ai/news/alphabets-robotics-software-platform-intrinsic-formally-integrates-with-google/